

Laboratorium 11 - Optymalizacja

Mateusz Podmokły - II rok Informatyka WI

6 czerwiec 2024

1 Treść zadania

Zadanie 1. Wyznacz punkty krytyczne każdej z poniższych funkcji. Scharakteryzuj każdy znaleziony punkt jako minimum, maksimum lub punkt siodłowy. Dla każdej funkcji zbadaj, czy posiada minimum globalne lub maksimum globalne na zbiorze \mathbb{R}^2 .

$$f_1(x, y) = x^2 - 4xy + y^2$$

$$f_2(x, y) = x^4 - 4xy + y^4$$

$$f_3(x, y) = 2x^3 - 3x^2 - 6xy(x - y - 1)$$

$$f_4(x, y) = (x - y)^4 + x^2 - y^2 - 2x + 2y + 1$$

Zadanie 2. Funkcja celu użyta do optymalizacji $F(x^{(0)}, x^{(1)}, \dots, x^{(n)})$ zdefiniowana jest jako

$$F(x^{(0)}, x^{(1)}, \dots, x^{(n)}) = \lambda_1 \sum_{i=0}^n \sum_{j=1}^k \frac{1}{\epsilon + \|x^{(i)} - r(j)\|_2^2} + \lambda_2 \sum_{i=0}^{n-1} \|x^{(i+1)} - x^{(i)}\|_2^2$$

2 Specyfikacja użytego środowiska

Specyfikacja:

- Środowisko: Visual Studio Code,
- Język programowania: Python,
- System operacyjny: Microsoft Windows 11,
- Architektura systemu: x64.

3 Rozwiązanie problemu

3.1 Biblioteki

W realizacji rozwiązania wykorzystane zostały następujące biblioteki:

```
1 import numpy as np
```

3.2 Zadanie 1.

Punkty krytyczne zostały znalezione przy pomocy metody Newtona. Metoda Newtona wybiera punkt startowy x_0 i wykonuje kolejne iteracje przybliżające rozwiązanie:

$$x_{k+1} = x_k - H(x_k)^{-1} \nabla f(x_k)$$

gdzie $\nabla f(x, y)$ to gradient funkcji f dany wzorem

$$\nabla f(x, y) = \begin{bmatrix} \frac{\partial f}{\partial x}(x, y) \\ \frac{\partial f}{\partial y}(x, y) \end{bmatrix}$$

a $H(x, y)$ to macierz Hessego dana wzorem

$$H(x, y) = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2}(x, y) & \frac{\partial^2 f}{\partial x \partial y}(x, y) \\ \frac{\partial^2 f}{\partial y \partial x}(x, y) & \frac{\partial^2 f}{\partial y^2}(x, y) \end{bmatrix}$$

Punkt krytyczny jest minimum, jeżeli wszystkie wartości własne macierzy Hessego są większe od 0, maksimum jeżeli są mniejsze od 0, a punktem siodłowym w każdej innej sytuacji. Wartości własne macierzy A można wyznaczyć z równania

$$\det(A - \lambda I) = 0$$

gdzie $\det()$ to wyznacznik macierzy, a I to macierz jednostkowa. Do obliczenia wartości własnych wykorzystałem funkcję z biblioteki NumPy

```
np.linalg.eig
```

3.3 Zadanie 2.

3.3.1 Gradient funkcji celu

Na początku wyprowadzamy wzór na pochodną cząstkową funkcji celu F . Dla $i \in [1, n - 1]$ mamy

$$\frac{\partial F}{\partial x^{(i)}} = 2\lambda_2(x_{i+1} - x_{i-1}) - \lambda_1 \sum_{j=1}^k \frac{2(x_i - r_j)}{\epsilon + \|x_i - r_j\|^4}$$

dla $i = 0$

$$\frac{\partial F}{\partial x^{(0)}} = 2\lambda_2(x_1 - x_0) - \lambda_1 \sum_{j=1}^k \frac{2(x_0 - r_j)}{\epsilon + \|x_0 - r_j\|^4}$$

a dla $i = n$

$$\frac{\partial F}{\partial x^{(n)}} = 2\lambda_2(x_n - x_{n-1}) - \lambda_1 \sum_{j=1}^k \frac{2(x_n - r_j)}{\epsilon + \|x_n - r_j\|^4}$$

Zatem, gradient funkcji F dany jest wzorem

$$\nabla F = \begin{bmatrix} \frac{\partial F}{\partial x^{(0)}} \\ \vdots \\ \frac{\partial F}{\partial x^{(n)}} \end{bmatrix}$$

3.3.2 Algorytm największego spadku

Algorytm iteracyjny polega na przybliżaniu minimum zadanej funkcji celu F . Polega na wybraniu punktu początkowego x_0 i obliczaniu w kolejnych iteracjach

$$x_{k+1} = x_k + \alpha_k d_k$$

gdzie

$$d_k = -\nabla F(x_k)$$

a α_k to minimum funkcji F wzdłuż kierunku d_k .

4 Przedstawienie wyników

4.1 Zadanie 1.

Zestawienie punktów krytycznych funkcji.

Funkcja f_1 :

- $(0, 0)$ - punkt siodłowy, $x_0 = (1, 1)$

Funkcja f_2 :

- $(-1, -1)$ - minimum, $x_0 = (-2, -2)$
- $(1, 1)$ - minimum, $x_0 = (2, 2)$
- $(0, 0)$ - punkt siodłowy, $x_0 = (-0.5, 0)$

Funkcja f_3 :

- $(-1, -1)$ - maksimum, $x_0 = (-2, -2)$
- $(1, 0)$ - minimum, $x_0 = (2, 0)$
- $(0, -1)$ - punkt siodłowy, $x_0 = (0, -2)$
- $(0, 0)$ - punkt siodłowy, $x_0 = (0, 1)$

Funkcja f_4 :

- $(1, 1)$ - punkt siodłowy, $x_0 = (0, 0)$

5 Wnioski

Metoda Newtona jest skutecznym sposobem znajdowania punktów krytycznych funkcji. Powinniśmy pamiętać o odpowiednim doborze punktów początkowych x_0 . Optymalizacja funkcji celu jest przydatnym zagadnieniem odpowiadającym na szeroki zakres problemów.

6 Bibliografia

[https://pl.wikipedia.org/wiki/Metoda_Newtona_\(optymalizacja\)](https://pl.wikipedia.org/wiki/Metoda_Newtona_(optymalizacja))
https://pl.wikipedia.org/wiki/Metoda_najszybszego_spadku
[https://pl.wikipedia.org/wiki/Gradient_\(matematyka\)](https://pl.wikipedia.org/wiki/Gradient_(matematyka))
<https://home.agh.edu.pl/~gora/algebra/Wyklad07.pdf>
https://pl.wikipedia.org/wiki/Macierz_Hessego
https://pl.wikipedia.org/wiki/Pochodna_cz%C4%85stkowa